

MANUAL TÉCNICO

RAG HVAC Assistant

Arquitectura, instalación, operación y continuidad del prototipo

Trabajo de graduación de Ingeniería Informática

Universidad Centroamericana José Simeón Cañas

Autores

Rodrigo Andrés Mena Caballero

Duglas Fernando Pineda Fuentes

Mario Antonio Martinez Villatoro

Director: James Edward Humberstone Morales

Línea base documental: `commit a7872e64e0398d9b45974afcde4b1d23f9c84ae2`

Revisión técnica: 16 de julio de 2026

Control documental

Campo	Valor
Documento	Manual técnico de RAG HVAC Assistant
Propósito	Transferir conocimiento técnico para instalación, operación, mantenimiento y continuidad académica.
Línea base	Commit a7872e64e0398d9b45974afcde4b1d23f9c84ae2, fechado el 21 de mayo de 2026.
Alcance del código	Exclusivamente los 120 archivos rastreados por Git en la línea base auditada.
Fuente académica	Tesis asociada de 84 páginas, indicada expresamente por los autores como fuente contextual.
Idioma	Español, con identificadores de código conservados en inglés.
Audiencia	Estudiantes, docentes, mantenedores y evaluadores técnicos del prototipo.

Criterio de inclusión: Los manuales PDF locales, índices Chroma, documentos auxiliares no rastreados y cualquier cambio sin commit se excluyeron de la descripción técnica del software. El PDF de tesis se utilizó únicamente para contexto académico porque fue solicitado de forma explícita; no se lo presenta como archivo distribuido por Git.

Cómo utilizar este manual

El documento está organizado para permitir dos recorridos. Quien necesite ejecutar el prototipo puede avanzar desde los capítulos de instalación y operación. Quien deba extenderlo debe comenzar por la arquitectura, los contratos de datos y las limitaciones registradas.

- Capítulos 1 a 3: contexto, alcance y vista general de la solución.
- Capítulos 4 a 8: arquitectura detallada del backend, RAG, ingesta y frontend.
- Capítulos 9 a 12: instalación, operación, API, configuración y persistencia.
- Capítulos 13 a 17: seguridad, calidad, mantenimiento, diagnóstico de fallos y continuidad.
- Apéndices: inventario funcional, glosario y listas de verificación.

Índice de contenidos

- 1. Introducción y contexto académico
- 2. Alcance de la línea base
- 3. Arquitectura general
- 4. Backend y API FastAPI
- 5. Recuperación y generación RAG
- 6. Ingesta de manuales y contenido visual
- 7. Persistencia conversacional
- 8. Frontend React
- 9. Instalación y puesta en marcha
- 10. Operación del sistema
- 11. Referencia de API
- 12. Configuración y datos persistentes
- 13. Seguridad y privacidad
- 14. Calidad, verificación y deuda técnica
- 15. Guía de mantenimiento y extensión
- 16. Solución de problemas
- 17. Continuidad académica recomendada
- Apéndice A. Mapa del repositorio
- Apéndice B. Glosario
- Apéndice C. Listas de verificación

1. Introducción y contexto académico

1.1 Problema atendido

Los procedimientos de diagnóstico HVAC se encuentran distribuidos en manuales de servicio extensos, generalmente organizados por fabricante y modelo. Buscar códigos de falla, valores de medición, diagramas o secuencias de reparación de forma manual introduce demora y dificulta conservar la trazabilidad de la evidencia utilizada.

La investigación asociada señala además una limitación de los modelos de lenguaje de propósito general: pueden producir respuestas plausibles sin disponer de la documentación oficial del equipo. La arquitectura RAG intenta reducir este riesgo mediante recuperación semántica previa y generación condicionada por fragmentos del manual.

1.2 Objetivo del prototipo

El objetivo general de la tesis fue implementar un prototipo funcional que permitiera interacción directa con el técnico. En el código auditado, este objetivo se concreta mediante una SPA para consulta y gestión documental, una API que coordina conversaciones e ingesta, un almacén vectorial persistente y servicios Gemini para embeddings, visión y generación.

Alcance operativo: El producto apoya el diagnóstico; no toma decisiones autónomas ni sustituye procedimientos de seguridad, certificaciones del fabricante o juicio profesional.

1.3 Alcance del caso de estudio

- Equipos de aire acondicionado Split de muro o pared.
- Entornos residenciales y comerciales ligeros.
- Tecnología convencional e Inverter.
- Capacidades entre 9,000 y 24,000 BTU dentro del estudio académico.
- Componentes principales: unidades interior y exterior, controles, sensores y drenaje.

La tesis organizó la evaluación alrededor de diecinueve fallas frecuentes. El software actual no implementa una lista blanca de esas fallas: acepta consultas abiertas y depende del corpus, de la recuperación y del prompt. Por ello, el alcance académico no debe confundirse con una restricción ejecutable.

1.4 Resultados reportados por la investigación

Indicador	Resultado	Interpretación correcta
Participantes	5 técnicos HVAC	Muestra de evaluación académica, no población general.
Preguntas específicas	14/15 correctas y completas (93 %)	Valor observado en las sesiones documentadas.

Indicador	Resultado	Interpretación correcta
Citación explícita	13/15 (87 %)	No equivale a trazabilidad perfecta en cualquier consulta.
Recuperación del embedding	Hit rate de 80 %	Resultado del benchmarking descrito por la tesis.
Tiempo de respuesta	2 a 10 segundos	Medición contextual, dependiente de red, cuota, corpus y hardware.

La investigación documentó una alucinación de transferencia de dominio al consultar un equipo VRF de alta capacidad no cubierto por el corpus. Este hallazgo justifica tratar los resultados favorables como evidencia experimental y no como garantía de seguridad.

2. Alcance de la línea base

2.1 Regla de auditoría

La descripción se obtuvo de ``git ls-files`` y se corroboró leyendo el contenido de la línea base. La auditoría comprendió 120 archivos rastreados: 48 bajo ``backend``, 70 bajo ``frontend`` y 2 archivos en la raíz del repositorio.

Área	Elementos relevantes incluidos	Elementos locales excluidos
Backend	Aplicación FastAPI, Dockerfile, requisitos, configuración, SQLite versionada y directorios con <code>.gitkeep</code> .	Entorno virtual, <code>.env</code> real, PDF cargados, Chroma local e imágenes generadas.
Frontend	Código React/TypeScript, configuración, lockfile, SVG institucional y documentación de plantilla.	<code>node_modules</code> , <code>dist</code> y archivos de entorno locales.
Raíz	README anterior y <code>.gitignore</code> .	Planes, reportes, instrucciones de agentes y documentación auxiliar no rastreada.

2.2 Estado funcional comprobado

- El backend contiene 2,658 líneas de módulos Python bajo ``app`` y 3,031 líneas en el conjunto versionado del backend.
- El frontend contiene 70 archivos rastreados y aproximadamente 3,724 líneas en su conjunto auditado.
- El parseo sintáctico de los módulos Python rastreados fue correcto.
- La compilación de producción del frontend finalizó correctamente.
- El lint del frontend presenta cuatro errores conocidos, descritos en el capítulo 14.
- No existen pruebas automatizadas ni canalización de integración continua en la línea base.

2.3 Diferencias respecto de documentación anterior

La documentación anterior no representaba la arquitectura actual. Entre las diferencias verificadas se encuentran la incorporación de SQLite y SQLAlchemy, CRUD de conversaciones, cuentas demo, Docker, dos claves Gemini, Chroma bajo ``backend/data/chroma_db``, extracción de imágenes, galería de diagramas y una tercera vista de créditos en el frontend.

Regla de mantenimiento: Toda actualización futura de este manual debe comenzar por el código y los manifiestos versionados. Los documentos de planificación son fuentes secundarias y no deben asumirse vigentes sin corroboración.

3. Arquitectura general

3.1 Componentes y responsabilidades

Componente	Responsabilidad	Persistencia o dependencia
SPA React	Interacción, navegación por estado, chat, cuentas demo, manuales y créditos.	localStorage para preferencias; API para historial.
FastAPI	Contratos HTTP, CORS, archivos estáticos y coordinación de servicios.	Proceso síncrono de un worker en Docker.
RAGService	Inferencia de modo, recuperación, síntesis, filtrado de fuentes y caché del índice.	LlamaIndex, Gemini y ChromaDB.
IngestService	Lectura, visión, fragmentación, embeddings, indexación y progreso.	Estado en memoria; una ingesta pretendida a la vez.
SQLite	Conversaciones, mensajes, propietarios demo y fuentes serializadas.	`backend/data/conversations.db`.
ChromaDB	Vectores y metadatos de fragmentos.	`backend/data/chroma_db`.
PyMuPDF	Texto por página, complejidad visual, imágenes y renderizados.	PDF e imágenes en disco.
Google GenAI	Embeddings, descripciones visuales y respuestas.	Servicio externo sujeto a cuota.

3.2 Secuencia de consulta

1. El usuario selecciona una cuenta demo, una conversación y opcionalmente una marca.
2. El frontend envía `POST /api/chat` con la cabecera `X-Demo-User`.
3. El backend valida propiedad de la conversación o crea una nueva, recupera el historial y registra el mensaje del usuario dentro de la transacción actual.
4. RAGService infiere el modo, abre o reutiliza el índice y recupera fragmentos desde ChromaDB.
5. Gemini sintetiza la respuesta con el prompt correspondiente y el idioma detectado.
6. El backend filtra fuentes, persiste el mensaje del asistente y confirma la transacción SQLite.
7. La SPA muestra respuesta, respaldo documental y galería de diagramas elegibles.

3.3 Secuencia de ingesta

8. La ruta de carga guarda el PDF y registra una tarea `BackgroundTasks`.
9. El servicio extrae marca del nombre y recorre las páginas con PyMuPDF.
10. Se extraen imágenes relevantes y se describen páginas candidatas con Gemini Vision.
11. Se crea un documento LlamaIndex por página y luego se fragmenta con `SentenceSplitter`.

12. El modelo de embeddings convierte los nodos en vectores.
13. Los lotes se insertan en ChromaDB y el índice en memoria se invalida.

4. Backend y API FastAPI

4.1 Arranque de la aplicación

`backend/app/main.py` crea los directorios de datos tanto al importar como durante el ciclo de vida. En el `lifespan` configura el motor SQLite, registra modelos ORM, crea tablas y ejecuta una migración ligera para añadir `owner\_id` cuando se abre una base antigua.

Después monta `/images`, configura CORS e incorpora los routers de salud, conversaciones, chat y documentos. Swagger queda en `/docs` y ReDoc en `/redoc`. La variable `debug` existe en Settings, pero no se pasa al constructor de FastAPI y actualmente no modifica el comportamiento.

4.2 Inyección de dependencias

`app/core/dependencies.py` expone `Settings`, `DocumentService`, `RAGService` e `IngestService` como singletons mediante `@lru\_cache`. Esta decisión comparte la caché del índice y el estado de ingesta dentro de un proceso. Las sesiones SQLAlchemy, en cambio, se crean y cierran por solicitud.

Implicación: Múltiples workers o réplicas no comparten bloqueo, progreso ni caché. La imagen Docker fija `--workers 1`, coherente con esta restricción.

4.3 Organización interna

Paquete	Responsabilidad principal
app/api	Rutas HTTP y dependencia de propietario demo.
app/core	Settings, rutas de datos y fábricas de servicios.
app/db	Base ORM, modelos, sesión y migración ad hoc.
app/rag	Chroma, embeddings, claves, LLM, visión, extracción PDF, prompts y postprocesado.
app/schemas	Modelos Pydantic de chat, conversación y documentos.
app/services	Casos de uso de consulta, ingesta y listado de manuales.
app/util	Títulos, contexto conversacional, timestamps e idioma.

4.4 Contratos de chat

`ChatRequest` exige un `message` de al menos un carácter y admite `conversation\_id`, `mode` y `brand`. El resultado incluye `answer`, `conversation\_id` y fuentes con texto, archivo, similitud, página, indicador de contexto gráfico y URLs de imagen.

La ruta convierte errores de cuota en 429, errores ascendentes 5xx en 503, entradas inválidas en 400 y fallos no clasificados en 500. Los mensajes visibles se simplifican para no exponer directamente la excepción de Gemini.

4.5 Contratos de documentos

La carga lee el archivo completo en memoria, limita el tamaño a `MAX_UPLOAD_MB`, valida el sufijo `.pdf`, rechaza duplicados y devuelve 202. El progreso expone `idle`, `processing`, `done` o `error`, con las fases `validating`, `reading_pages`, `chunking` e `indexing`.

Eliminar un manual borra el archivo, solicita a Chroma la eliminación por `file_name`, invalida el índice y elimina su directorio de imágenes. Algunas excepciones Chroma se silencian, por lo que una respuesta exitosa no garantiza que no queden vectores huérfanos.

5. Recuperación y generación RAG

5.1 Preparación de la consulta

La pregunta se normaliza colapsando espacios y convirtiendo códigos alfanuméricos a mayúsculas. La marca, si se proporciona, se normaliza a minúsculas y se aplica como filtro exacto de metadatos.

La detección de códigos utiliza palabras clave en español e inglés, patrones alfanuméricos, números precedidos por contexto de falla y números mostrados en pantalla. Se excluyen tokens frecuentes que no suelen ser códigos, como refrigerantes `R32`, `R410A` y terminales `L1`, `L2` o `T1`.

5.2 Perfiles de recuperación

Perfil	Criterio	top_k	Síntesis	Prompt
Código de error	Palabra clave o patrón de código.	3	compact	ERROR_CODE_QA_TEMPLAT E
Diagnóstico	Predeterminado.	5	tree_summarize	TEXT_QA_TEMPLATE
Diagrama	Consulta explícita sobre figura, esquema o cableado.	8	tree_summarize	TEXT_QA_TEMPLATE

Las preguntas de 120 caracteres o más incrementan `top\_k` en uno. Ambos prompts instruyen al modelo a usar solo el contexto, declarar insuficiencia, evitar datos inventados y respetar el idioma obligatorio.

5.3 Contexto conversacional

Antes de consultar, se recuperan los mensajes de la conversación en orden cronológico.

`format\_prior\_messages\_for\_prompt` conserva hasta 20 mensajes recientes dentro de 3,500 caracteres y los etiqueta como Técnico o Asistente. La pregunta actual siempre se separa con `PREGUNTA ACTUAL:`.

Para los turnos de seguimiento, la síntesis recibe el contexto conversacional, pero la recuperación adicional de fuentes usa solo la pregunta actual. Esto evita que el tema previo domine la selección de diagramas.

5.4 Fuentes y galería

- Los nodos con menos de 12 caracteres se eliminan mediante `SkipEmptyNodePostprocessor`.
- Las fuentes comunes deben superar un piso de similitud de 0.515 y quedar a no más de 0.035 del mejor resultado.
- La galería exige al menos 0.535 y márgenes más estrictos para imágenes.
- Se muestran como máximo seis páginas con imágenes; no se rellena el cupo con figuras irrelevantes.

- Las fuentes no se muestran en preguntas demasiado cortas, meta o explícitamente contrarias al uso de manuales.

Limitación de seguridad: El filtrado de similitud mejora relevancia, pero no verifica compatibilidad de fabricante, tipo, capacidad o modelo. No existe un guardrail previo a la generación.

5.5 Claves y tolerancia a cuota

`iter\_google\_api\_keys` prioriza `GOOGLE\_API\_KEY` y después `GOOGLE\_API\_KEY\_FREE`, eliminando duplicados. Generación, embeddings y visión reintentan con la clave siguiente únicamente cuando la excepción parece corresponder a cuota o HTTP 429. Otros errores se propagan o, en visión, se registran y omiten.

6. Ingesta de manuales y contenido visual

6.1 Metadatos por página

`build\_documents\_from\_pdf` crea un documento LlamaIndex por página. Cada documento contiene `file\_name`, `page\_number`, `page\_label`, `has\_diagram\_context`, `image\_urls` serializadas en JSON y, cuando se infiere, `brand`. Una página sin texto recibe un marcador para que su procedencia no se pierda.

6.2 Selección visual

Una página se considera candidata a visión si contiene menos de 2,600 caracteres y presenta al menos una imagen o 150 trazados vectoriales. Con perfil de pago se describen hasta 10 páginas; con perfil gratuito, hasta 45. Si hay más candidatas, se priorizan las páginas con menos texto y mayor señal gráfica.

La página se renderiza a JPEG a 140 dpi, se reduce a 1,280 píxeles de ancho como máximo y utiliza calidad 82. Gemini recibe instrucciones para describir diagramas, componentes, tablas y leyendas sin inventar valores.

6.3 Extracción de imágenes

- Se descartan imágenes con un lado menor que 100 píxeles.
- Se descartan imágenes menores a 2,048 bytes.
- Se descartan proporciones superiores a 20:1 para evitar reglas y separadores.
- Si no hay imagen embebida y existen al menos 150 trazados, se renderiza la página completa a 150 dpi.
- Los archivos se guardan bajo `data/images/{nombre\_sin\_extensión}` y se sirven desde `/images`.

En la implementación actual, deshabilitar `DIAGRAM\_VISION\_ENABLED` también evita pasar el directorio de imágenes al extractor. Por tanto, la bandera desactiva tanto descripciones como galería, no solo llamadas a Gemini Vision.

6.4 Fragmentación e indexación

`SentenceSplitter` usa tamaño 1,024 y superposición 200. El modelo interno de embeddings utiliza el lote efectivo de 100 con clave pagada o 5 con clave gratuita. La inserción externa recorre nodos con `embedding\_batch\_size`, cuyo valor predeterminado es 100; por ello, el progreso puede avanzar en saltos mayores que las llamadas reales del modelo gratuito.

Recuperación ante fallos: La ingesta no es transaccional. Un error puede dejar el PDF, imágenes y vectores parciales. Antes de reintentar debe verificarse y, de ser necesario, eliminarse el manual desde la API y limpiarse su estado residual.

6.5 Concurrency

`IngestService` utiliza un `threading.Lock`, pero la ruta consulta `is\_busy()` antes de que la tarea de fondo marque el estado como `processing`. Dos cargas casi simultáneas pueden obtener 202; la segunda tarea puede retornar sin indexar y dejar un PDF en disco. Esta carrera debe corregirse reservando el trabajo de forma atómica antes de responder.

7. Persistencia conversacional

7.1 Modelo relacional

Tabla	Campos principales	Relación
conversations	id, owner_id, title, created_at, updated_at	Una conversación posee muchos mensajes.
messages	id, conversation_id, role, content, sources_json, created_at	FK hacia conversations; ORM con delete-orphan.

Los identificadores son UUID en texto. `owner\_id` tiene máximo 64 caracteres; la dependencia demo admite letras, números, punto, guion y guion bajo, y vuelve a `default` ante entradas inválidas. Esto es segmentación de demostración, no autenticación.

7.2 Ciclo de un turno

14. Se busca la conversación y se comprueba que pertenezca al propietario demo.
15. Se recupera el historial y se inserta el mensaje del usuario.
16. Se ejecuta RAG. Si falla, se revierte la transacción.
17. Se serializan fuentes como JSON de texto y se inserta el mensaje del asistente.
18. Se actualiza `updated\_at` y se confirma la transacción.

7.3 Migración y restricciones

No se utiliza Alembic. `schema\_migrate.py` solo agrega `owner\_id` a una base anterior. Cambios posteriores de esquema requerirán una estrategia formal. SQLite tampoco habilita de manera explícita `PRAGMA foreign\_keys=ON`; la cascada del ORM cubre el borrado normal desde la aplicación, pero no debe asumirse para operaciones SQL externas.

8. Frontend React

8.1 Árbol de proveedores

```
StrictMode
├─ AppProviders / AuthProvider
│   └─ DemoAccountProvider
│       └─ ChatWorkspaceProvider
│           └─ App
```

`App` mantiene tres vistas mediante estado: `chat`, `manuals` y `settings`. No existe React Router, rutas profundas ni navegación por URL. `settings` muestra créditos académicos; no permite modificar parámetros técnicos.

8.2 Cuentas demo

Hay siete perfiles: `default` y `usuario-1` a `usuario-6`. La selección se guarda bajo `rag-hvac-assistant:demo-owner-v1`; todas las llamadas de chat y conversaciones envían `X-Demo-User`. Cambiar de cuenta vacía el estado local y consulta el historial del nuevo propietario.

8.3 Estado de chat

`ChatWorkspaceProvider` administra conversaciones, selección, mensajes, creación, renombrado, eliminación, envío, carga y errores. Crea mensajes optimistas y después resincroniza con SQLite a través de la API.

`persistedAppState.ts` define una caché v1 para vista, conversaciones y mensajes. Sin embargo, el proveedor solo restaura inicialmente `selectedThreadId`; las listas comienzan vacías y se reconstruyen desde el backend. En consecuencia, SQLite es la persistencia efectiva del historial.

8.4 Cliente HTTP

- `chatApi.ts` usa un timeout de 90 segundos.
- Reintenta una vez ante 429, 502, 503 o 504.
- Transforma errores frecuentes en mensajes breves en español.
- `conversationsApi.ts` implementa listar, crear, recuperar mensajes, renombrar y eliminar.
- `manualsApi.ts` implementa listado, estado, carga multipart y eliminación.

Un timeout producido durante el segundo intento no vuelve a atravesar el mapeo exterior y puede propagarse como `AbortError`. Este caso debe corregirse en una futura refactorización del cliente.

8.5 Interfaz de chat

El compositor requiere texto, envía con Enter y conserva Shift+Enter para salto de línea. Incluye filtro de marca construido a partir de nombres de PDF indexados. Los tipos y componentes de adjuntos continúan en el repositorio, pero el compositor actual siempre envía una lista vacía; no existe selector ni carga de archivos en chat.

La respuesta admite una interpretación mínima de negrita con `***texto***`, no Markdown completo. Las fuentes muestran archivo, página, fragmento y enlace de descarga. La galería abre un lightbox y limita las imágenes a seis.

8.6 Gestión de manuales

`useManuals` solicita en paralelo la lista y el estado inicial. Mientras `status` sea `processing`, consulta cada dos segundos. La interfaz bloquea navegación y chat durante carga, procesamiento y una pausa visual de dos segundos después del éxito.

El componente de progreso sabe representar `error`, pero la capa que lo muestra deja de activarse cuando el estado ya no es `processing`. Además, `error_message` no se copia al error general. Por ello, un fallo de ingesta puede desaparecer sin explicación visible.

8.7 Accesibilidad y adaptabilidad

El frontend utiliza `lang=es`, etiquetas accesibles, roles de alerta, estado y diálogo, atributos `aria-live` y foco visible. La barra lateral móvil responde a Escape y la interfaz usa puntos de quiebre de Tailwind.

Los diálogos y el lightbox no atrapan ni restauran el foco, no bloquean desplazamiento y algunos controles carecen de relaciones ARIA completas. Estas brechas deben atenderse antes de considerar cumplimiento formal de accesibilidad.

9. Instalación y puesta en marcha

9.1 Preparación del backend

```
cd backend
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
cp .env.example .env
```

Edite `.env` y configure al menos una de las claves `GOOGLE_API_KEY` o `GOOGLE_API_KEY_FREE`. Ejecute el servidor desde `backend`; Pydantic busca `.env` respecto del directorio de trabajo y el paquete `app` debe resolverse correctamente.

```
uvicorn app.main:app --reload --host 0.0.0.0 --port 8000
```

9.2 Preparación del frontend

```
cd frontend
pnpm install
pnpm dev
```

La aplicación se publica por defecto en `http://localhost:5173` y consume `http://127.0.0.1:8000`. Para cambiar el backend, defina `VITE_API_BASE_URL` en un archivo local de entorno.

9.3 Inicio mediante Docker

```
docker build -t rag-hvac-backend backend
docker run --rm -p 8000:8000 --env-file backend/.env \
  -v "$(pwd)/backend/data:/app/data" rag-hvac-backend
```

El Dockerfile usa `python:3.12-slim`, instala herramientas de compilación, copia dependencias y código, expone 8000 y ejecuta un worker. No existe Docker Compose ni contenedor versionado del frontend.

Contexto de imagen: `.dockerignore` no excluye todos los datos locales. Antes de construir, compruebe que manuales, Chroma, imágenes, SQLite o secretos no entren accidentalmente en el contexto Docker.

9.4 Verificación inicial

19. Abra `/api/health`; debe responder `status: ok`. Esta prueba no valida Gemini, Chroma ni SQLite en profundidad.
20. Abra `/docs` para confirmar que los routers se cargaron.
21. Abra el frontend y seleccione Manuales técnicos.
22. Cargue un PDF no sensible con texto seleccionable.
23. Espere `done` y confirme que `indexed` sea verdadero.
24. Realice una consulta relacionada con el manual y verifique nombre de archivo y página.

10. Operación del sistema

10.1 Convención de nombres

```
100_ServiceManual_Daikin_FTXS-L_FDXS-L_Series.pdf
```

El servicio elimina el prefijo hasta `\_ServiceManual\_` y usa el primer token separado por guion bajo como marca en minúsculas. El patrón es sensible a mayúsculas y `.removesuffix(".pdf")` no elimina `.PDF`, aunque la ruta sí acepta esa extensión. Utilice nombres consistentes en minúscula para la extensión.

10.2 Cargar e indexar

25. Compruebe que ninguna ingesta esté activa.
26. Cargue un único PDF desde la UI o la API.
27. Observe las fases de validación, lectura, fragmentación e indexación.
28. Si la fase termina en error, anote el mensaje del endpoint antes de reiniciar el backend.
29. Confirme el manual en `GET /api/documents` y ejecute una consulta de control.

10.3 Eliminar y reindexar

Para aplicar cambios de visión, chunking, embeddings o metadatos a un manual existente, elimínelo mediante la API y vuelva a cargarlo. Copiar archivos al directorio no ejecuta indexación.

30. Haga una copia de seguridad si el PDF no puede recuperarse de su fuente.
31. Ejecute `DELETE /api/documents/{filename}`.
32. Verifique que desaparezcan el PDF, sus vectores y el directorio de imágenes.
33. Cargue nuevamente el archivo y espere a que termine la ingesta.

10.4 Copias de seguridad

Activo	Ruta	Recomendación
Conversaciones	data/conversations.db	Copiar con el backend detenido o usar respaldo consistente de SQLite.
Vectores	data/chroma_db	Copiar como unidad; conservar modelo y configuración asociados.
Manuales	data/manuals	Conservar fuente original y licencia de uso.
Imágenes	data/images	Regenerables desde el PDF, pero costosas si requieren visión.
Configuración	.env	Guardar en un gestor de secretos, nunca en Git.

10.5 Cuentas de demostración

Los perfiles permiten aislar historiales durante una demostración. No protegen información: el identificador viaja en una cabecera manipulable. No almacene conversaciones personales, datos de clientes ni información contractual en la base versionada.

11. Referencia de API

11.1 Endpoints generales y de chat

Método y ruta	Entrada	Salida o efecto
GET /	Ninguna	Metadatos y enlaces de servicio.
GET /api/health	Ninguna	Liveness básico.
POST /api/chat	ChatRequest + X-Demo-User	ChatResponse; persiste turno completo.

11.2 Conversaciones

Método y ruta	Estado normal	Descripción
POST /api/conversations	201	Crea una conversación del propietario demo.
GET /api/conversations	200	Lista por `updated_at` descendente.
GET /api/conversations/{id}/messages	200	Devuelve mensajes cronológicos y fuentes.
PATCH /api/conversations/{id}	200	Renombra y actualiza fecha.
DELETE /api/conversations/{id}	204	Elimina conversación y mensajes vía ORM.

11.3 Documentos

Método y ruta	Estado normal	Descripción
GET /api/documents	200	Lista PDF en disco y presencia de vectores.
POST /api/documents/upload	202	Guarda PDF e inicia tarea de ingesta.
GET /api/documents/ingest-status	200	Expone estado y progreso en memoria.
GET /api/documents/{filename}/download	200	Descarga un PDF.
DELETE /api/documents/{filename}	204	Borra PDF, Chroma, imágenes y caché.
GET /images/...	200	Sirve recursos visuales sin autenticación.

11.4 Estados de error relevantes

Estado	Situación principal
400	Consulta inválida, conversación impropia o nombre de archivo rechazado según la ruta.
404	Conversación o documento inexistente; también oculta conversaciones de otro propietario.
409	Ya existe un PDF con el mismo nombre.
413	PDF supera el límite configurado.
422	Extensión inválida o validación Pydantic.
423	El servicio detecta una ingesta en curso.
429	Cuota temporal de Gemini.
500	Fallo no clasificado.
503	Servicio externo no disponible.

12. Configuración y datos persistentes

12.1 Variables esenciales

Variable	Predeterminado	Función
GOOGLE_API_KEY	vacío	Clave primaria.
GOOGLE_API_KEY_FREE	vacío	Clave gratuita o de respaldo.
GEMINI_LLM_MODEL	models/gemini-2.5-flash	Generación y visión por defecto.
GEMINI_EMBEDDING_MODEL	gemini-embedding-001	Representación vectorial.
MANUALS_DIR	data/manuals	Almacenamiento PDF.
IMAGES_DIR	data/images	Recursos visuales.
CHROMA_DB_PATH	data/chroma_db	Persistencia vectorial.
CONVERSATIONS_DB_PATH	data/conversations.db	SQLite.
MAX_UPLOAD_MB	50	Límite por archivo.
CORS_ORIGINS	localhost:5173; 127.0.0.1:5173	Orígenes permitidos.

12.2 Recuperación e ingesta

Parámetro	Valor	Observación
rag_chunk_size / overlap	1024 / 200	Configuración aplicada por SentenceSplitter.
diagnosis / error / diagram top_k	5 / 3 / 8	La consulta larga suma uno.
source score floor / margin	0.515 / 0.035	Filtro de fuentes comunes.
gallery min / max pages	0.535 / 6	Sin relleno de imágenes irrelevantes.
embedding paid batch / interval	100 / 0 s	Perfil Tier 1.
embedding free batch / interval	5 / 12 s	Perfil conservador.
vision paid pages / interval	10 / 0 s	Límite por PDF.
vision free pages / interval	45 / 2 s	Límite por PDF.
vision skip text	2600 caracteres	Página con más texto no usa visión.
vision image / drawing threshold	1 / 150	Criterio de candidatura.

12.3 Ubicaciones y vida útil

Estado	Ubicación	Vida útil
Índice abierto	RAGService._index	Hasta invalidación o reinicio.
Progreso de ingesta	IngestService._state	Hasta siguiente trabajo o reinicio.
Conversaciones	SQLite	Persistente en disco.
Vectores	ChromaDB	Persistente en disco.
Vista e ID seleccionado	localStorage ui-state-v1	Navegador; restauración parcial.
Cuenta demo	localStorage demo-owner-v1	Navegador.

13. Seguridad y privacidad

13.1 Modelo de amenazas actual

El prototipo fue construido para evaluación académica local. No implementa autenticación, autorización, cifrado de datos en reposo, gestión de sesiones, rate limiting, antivirus, auditoría formal ni aislamiento de documentos. Swagger, ReDoc, imágenes, manuales y endpoints documentales quedan públicos dentro del alcance de red del servidor.

13.2 Riesgos prioritarios

Prioridad	Riesgo	Tratamiento recomendado
Crítica	Path traversal en nombre de carga y comparación por prefijo en descarga/borrado.	Sanear nombre, generar ID de almacenamiento y usar <code>Path.is_relative_to`</code> o <code>relative_to`</code> .
Crítica	Respuesta fuera de dominio con apariencia confiable.	Clasificador/guardrail previo y rechazo conservador.
Alta	Suplantación por X-Demo-User.	Autenticación, autorización y propietario derivado de identidad verificada.
Alta	PDF malicioso o inválido.	Validar firma, MIME, estructura, límites, antivirus y procesamiento aislado.
Alta	Datos sensibles en SQLite versionada.	Retirar DB de Git, migrar a almacenamiento administrado y definir retención.
Media	Detalles internos en error de ingesta.	Registrar internamente y devolver códigos/mensajes controlados.
Media	Prompt injection desde manuales.	Separación de instrucciones, validación de salida y evaluación adversarial.

13.3 Controles antes de desplegar

- Restringir CORS a dominios de producción exactos.
- Deshabilitar o proteger documentación interactiva y recursos estáticos.
- Guardar secretos fuera de `.env`` y rotar claves expuestas.
- Ejecutar con usuario sin privilegios y límites de recursos.
- Separar almacenamiento por usuario o proyecto.
- Registrar operaciones de carga, consulta y eliminación sin almacenar secretos.
- Definir límites de consulta y de ingesta por identidad.
- Realizar pruebas de seguridad y evaluación RAG antes de cualquier uso en campo.

14. Calidad, verificación y deuda técnica

14.1 Estado de pruebas

No hay pytest, Vitest, React Testing Library, MSW, pruebas de recuperación ni CI. La validación de la línea base se limita a parseo de Python, build, lint y revisión manual. Esto es insuficiente para detectar regresiones en contratos, persistencia, similitud o seguridad.

14.2 Compilación y lint

Comando	Resultado auditado	Detalle
Parseo Python	Correcto	Todos los módulos Python rastreados.
pnpm build	Correcto	1,773 módulos; salida JS y CSS generada.
pnpm lint	Fallido	Cuatro errores en reglas de hooks y React Refresh.

Los errores se ubican en `ChatComposer.tsx`, `ChatThreadHeader.tsx` y `DemoAccountProvider.tsx` por `react-hooks/set-state-in-effect`, además de `react-refresh/only-export-components` en `DemoAccountProvider.tsx`.

14.3 Defectos funcionales registrados

- El error de ingesta puede desaparecer de la interfaz antes de mostrar su detalle.
- La reserva de ingesta no es atómica y permite una carrera entre cargas.
- La validación de rutas y PDF es insuficiente.
- Una ingesta fallida puede dejar artefactos parciales.
- La restauración de localStorage para mensajes no coincide con el esquema definido.
- El segundo timeout del cliente de chat puede propagarse sin traducción amistosa.
- Los diálogos carecen de manejo completo de foco.
- `index.html` referencia `/favicon.svg`, pero ese archivo no está rastreado.
- No hay desplazamiento explícito al último mensaje.

14.4 Estrategia de pruebas propuesta

Nivel	Cobertura mínima
Unidad backend	Detección de modo, idioma, títulos, propietarios, umbrales y rutas.
Integración backend	CRUD de conversaciones, transacciones, carga, progreso, eliminación y Chroma simulado.

Nivel	Cobertura mínima
RAG	Conjunto de preguntas, hit rate, precisión de fuente, fidelidad y rechazo fuera de dominio.
Frontend	Contextos, reintento, cuentas, carga, estados de error, fuentes y accesibilidad.
Seguridad	Traversal, PDF corrupto, cabeceras, CORS, cuota, prompt injection y exposición de archivos.
Extremo a extremo	PDF de prueba → ingesta → consulta → fuente → eliminación.

15. Guía de mantenimiento y extensión

15.1 Agregar una variable de configuración

34. Defina el campo tipado y su predeterminado en ``app/core/config.py``.
35. Agregue validación o propiedad efectiva si cambia según el perfil de cuota.
36. Documente el nombre en ``env.example`` sin incluir secretos.
37. Consuma el valor mediante ``get_settings``; no instancie Settings en rutas.
38. Añada pruebas de validación y actualice este manual y el README.

15.2 Agregar un endpoint

39. Defina schemas Pydantic bajo ``app/schemas``.
40. Implemente el caso de uso en un servicio si contiene lógica o persistencia.
41. Declare la ruta en el router de la característica y obtenga dependencias con ``Depends``.
42. Use mensajes de usuario en español y códigos HTTP coherentes.
43. Incluya el router en ``main.py`` si es nuevo y actualice el cliente TypeScript.
44. Añada pruebas, documentación OpenAPI y manejo de errores.

15.3 Cambiar chunking o embeddings

El cambio altera la geometría semántica del índice. Debe fijarse una línea base de evaluación, medir recuperación antes y después, crear una nueva colección o reindexar todos los manuales y registrar modelo, tamaño, superposición y fecha. No mezcle embeddings de modelos diferentes en una misma colección.

15.4 Extender modos de consulta

45. Defina el nuevo literal en schemas.
46. Aísle reglas de detección y falsos positivos.
47. Seleccione ``top_k``, síntesis y prompt mediante configuración.
48. Construya preguntas positivas, negativas y ambiguas para evaluación.
49. Revise política de exposición de fuentes e imágenes.

15.5 Mejorar el pipeline visual

Una evolución recomendable es indexar regiones de página con cajas delimitadoras, captions y vínculos a la página original. La recuperación debería seleccionar región y texto, mientras un modelo multimodal valida el diagrama recuperado antes de responder. Esta mejora debe evaluarse por precisión visual y costo, no solo por estética de la galería.

15.6 Migrar la persistencia

Para uso multiusuario, sustituya la SQLite versionada por PostgreSQL u otro servicio administrado; introduzca migraciones Alembic, transacciones explícitas, propietarios autenticados y políticas de retención. El almacenamiento de PDF e imágenes debe migrarse a objetos con URLs firmadas y controles de acceso.

16. Solución de problemas

Síntoma	Causa probable	Acción
`app` no se resuelve	Uvicorn ejecutado fuera de backend o venv inactivo.	Entre a `backend`, active `.venv` y vuelva a ejecutar.
No hay manuales indexados	PDF copiado sin pasar por ingesta o colección vacía.	Cargue mediante UI/API y espere `done`.
429 / cuota	Límite Gemini.	Espere, configure clave de respaldo o revise perfil de cuota.
PDF visible pero `indexed=false`	Ingesta falló, estado reiniciado o metadatos Chroma ausentes.	Consulte estado/log, elimine y reingeste.
No aparecen diagramas	Visión desactivada, página sin candidato o score bajo.	Revise configuración, reindexe y formule consulta explícita.
Diagrama equivocado	Recuperación semántica insuficiente.	Incluya fabricante, modelo, componente y tipo de diagrama.
Historial equivocado o vacío	Cuenta demo distinta o backend no disponible.	Compruebe selector, X-Demo-User y API.
Frontend sin conexión	VITE_API_BASE_URL o CORS incorrectos.	Alinee URL y CORS_ORIGINS; reinicie servicios.
Lint falla	Deuda conocida de hooks/refresh.	Refactorice los cuatro errores antes de exigir lint en CI.
Error de ingesta desaparece	Defecto de lock visual del frontend.	Consulte `/api/documents/ingest-status` y logs; corrija la UI.

16.1 Diagnóstico controlado

50. Registre commit, sistema operativo, versiones y configuración no secreta.
51. Reproduzca con un PDF pequeño y conocido.
52. Consulte health, documentos y estado de ingesta.
53. Revise logs del backend sin copiar claves ni contenido sensible.
54. Aísle si el fallo pertenece a PDF, visión, embeddings, Chroma, LLM, SQLite o frontend.
55. Elimine artefactos parciales solo después de conservar evidencia útil.
56. Añada una prueba de regresión antes de cerrar el defecto.

17. Continuidad académica recomendada

17.1 Prioridades

Orden	Iniciativa	Resultado esperado
1	Saneamiento de rutas y validación de PDF	Cerrar exposición crítica de archivos.
2	Guardrail de dominio	Rechazar equipos, marcas o capacidades no cubiertos.
3	Pruebas y conjunto de evaluación	Medir regresiones de recuperación y fidelidad.
4	Cola durable e idempotencia	Ingesta recuperable y segura ante concurrencia.
5	Autenticación y almacenamiento por usuario	Separación real de datos.
6	Preguntas aclaratorias	Mejorar consultas coloquiales o incompletas.
7	Recuperación multimodal por regiones	Razonamiento más preciso sobre diagramas.
8	Observabilidad y control de costos	Latencia, cuota, errores y trazabilidad operativa.

17.2 Protocolo para una cohorte futura

57. Congele una línea base Git y un conjunto de evaluación sin datos restringidos.
58. Reproduzca las métricas actuales antes de modificar el pipeline.
59. Formule una hipótesis medible, por ejemplo, reducción de errores fuera de dominio.
60. Implemente la mejora detrás de configuración o versión de colección.
61. Compare recuperación, fidelidad, latencia, costo y seguridad.
62. Documente resultados negativos y casos borde, no solo promedios.
63. Actualice README, manual, arquitectura y procedimientos de migración.

17.3 Criterios de salida a un piloto

- Autenticación y autorización probadas.
- Traversal, carga maliciosa y exposición de recursos corregidos.
- Guardrail fuera de dominio con pruebas adversariales.
- Ingesta durable, idempotente y observable.
- Migraciones y copias de seguridad restauradas en ensayo.
- Pruebas automatizadas obligatorias en CI.
- Evaluación con corpus representativo y revisión experta.
- Política de privacidad, retención, licencias y consentimiento.

- Advertencias de seguridad y procedimiento de escalamiento humano.

Apéndice A. Mapa del repositorio

backend/app/main.py	Entrada FastAPI y lifespan
backend/app/api/routes_chat.py	Consulta RAG y persistencia
backend/app/api/routes_conversations.py	CRUD del historial
backend/app/api/routes_documents.py	Gestión e ingesta de PDF
backend/app/core/config.py	Settings y valores efectivos
backend/app/db/models.py	Conversation y Message
backend/app/rag/manual_pdf_documents.py	Texto, visión e imágenes
backend/app/rag/embeddings.py	Throttling y fallback
backend/app/rag/vector_store.py	Apertura e inserción Chroma
backend/app/services/rag_service.py	Recuperación y fuentes
backend/app/services/ingest_service.py	Pipeline y progreso
frontend/src/main.tsx	Árbol de proveedores
frontend/src/App.tsx	Vistas y bloqueo global
frontend/src/features/chat/context/	Estado conversacional
frontend/src/features/chat/services/	Clientes de chat e historial
frontend/src/features/manuals/	Carga, polling y UI
frontend/src/features/demo-account/	Cuenta demo activa
frontend/src/features/settings/	Créditos académicos
frontend/src/lib/persistedAppState.ts	Esquema local v1

Apéndice B. Glosario

Término	Definición en este proyecto
RAG	Generación condicionada por información recuperada de un corpus.
Chunk	Fragmento textual generado a partir de una página del manual.
Embedding	Vector numérico que representa semánticamente texto o consulta.
ChromaDB	Almacén persistente de vectores y metadatos.
top_k	Cantidad máxima inicial de vecinos recuperados.
Grounding	Vinculación de una respuesta con evidencia documental recuperada.
Hallucination	Contenido generado sin respaldo suficiente o incorrectamente transferido.
Guardrail	Control previo o posterior que restringe respuestas inseguras.
Tier 1	Perfil de cuota de pago usado para mayor rendimiento de API.
Cuenta demo	Identificador de prueba que segmenta historial sin autenticar.
Ingesta	Proceso de lectura, enriquecimiento, fragmentación e indexación.
Fuente	Fragmento y metadatos presentados como evidencia de la respuesta.

Apéndice C. Listas de verificación

C.1 Antes de desarrollar

- Confirmar que el árbol de trabajo no contenga datos sensibles.
- Registrar commit base y estado de dependencias.
- Leer README, manual y código del área afectada.
- Definir criterio de aceptación y prueba de regresión.
- Separar configuración, código y datos de evaluación.

C.2 Antes de una demostración

- Comprobar claves y cuota sin exponerlas.
- Respalidar SQLite y datos necesarios.
- Cargar manuales autorizados y verificar indexación.
- Probar una consulta general, un código y un diagrama.
- Confirmar aislamiento visual de cuentas demo.
- Preparar respuesta ante cuota o caída de red.
- Recordar a participantes que el sistema no sustituye al técnico.

C.3 Antes de publicar cambios

- Ejecutar parseo o tests backend disponibles.
- Ejecutar ``pnpm build`` y ``pnpm lint``.
- Revisar migraciones y reindexación requerida.
- Comprobar errores, accesibilidad y comportamiento móvil.
- Revisar seguridad de rutas, cabeceras, archivos y secretos.
- Actualizar README, manual y ``.env.example``.
- Confirmar que solo se incluyen archivos intencionales en Git.

C.4 Cierre

Principio rector: La continuidad de este trabajo exige conservar la trazabilidad entre hipótesis académica, código versionado, datos de evaluación y evidencia de resultados. Una mejora no está completa hasta que puede reproducirse, medirse y mantenerse con seguridad.